中国科学技术大学软件学院

软件工程实验项目环节

开题报告

项 目 名 称：基于 RAG 的轻量级企业工艺生成系统

成 员 名 单：熊佳昀 齐梦伟 张承伟 资唯

导　　师：丁菁

工 程 领 域：软件工程

研 究 方 向：人工智能与检索增强生成

开 题 时 间：2026 年 10 月

中国科学技术大学软件学院

填表日期：2026 年 10 月 24 日

一、 简况

<table>
<tr><td rowspan="2">名称</td><td>中文</td><td colspan="3">基于 RAG 的轻量级企业工艺生成系统</td></tr>
<tr><td>英文</td><td colspan="3">A Lightweight Enterprise Manufacturing Process Generation System Based on Retrieval-Augmented Generation</td></tr>
<tr><td rowspan="5">项目组成员名单</td><td>姓名</td><td>学号</td><td>项目中的分工</td><td>签 章</td></tr>
<tr><td>熊佳昀</td><td>SA26225374</td><td>项目负责人。总体架构设计、需求分析；RAG 生成模块（Prompt 工程、大模型 API、结构化输出）；多轮对话查询改写；系统集成与项目管理、文档统筹。</td><td></td></tr>
<tr><td>齐梦伟</td><td>SA26225260</td><td>离线建库链路。工艺 PDF 解析（PyMuPDF/pdfplumber）、表格抽取与版面识别；文档分块策略（递归分块、表格保护、重叠）；Embedding 向量化与 Chroma 入库。</td><td></td></tr>
<tr><td>张承伟</td><td>SA26225429</td><td>检索核心模块。稠密向量检索、BM25 稀疏检索、RRF 融合；Cross-encoder 重排序（bge-reranker）；检索参数调优与召回率对比实验。</td><td></td></tr>
<tr><td>资唯</td><td>SA26225501</td><td>引用溯源（metadata 页码定位）；Gradio Web 交互界面；多轮对话历史管理；系统集成联调；多文档测试、人工评估与结果分析。</td><td></td></tr>
</table>

<table>
<tr><td>中英文摘要</td><td>

（中文 400 字左右）

本项目针对机械加工领域工艺知识高度依赖人工经验、工艺手册检索效率低、通用大模型直接生成加工参数易产生幻觉且缺乏可追溯性的问题，设计并实现一个基于检索增强生成（RAG）的轻量级企业工艺生成系统。系统采用“离线建库+在线问答”双链路架构：离线链路对工艺文档 PDF 进行解析、表格抽取、语义分块与向量化，构建基于 Chroma 的稠密向量索引和基于 BM25 的稀疏关键词索引；在线链路对用户问题进行多轮查询改写，采用稠密与稀疏双路混合召回并以 RRF 融合，再通过 Cross-encoder 重排序精排，最终由大模型结合检索资料生成结构化加工指令并支持引用溯源。系统基于开源 Chroma、BGE-M3、bge-reranker 及大模型 API，实现文档解析、混合检索、重排序、多轮对话与引用溯源等功能，并在多份工艺文档上通过人工评估检验其准确率与生成质量。本系统对降低工艺知识获取门槛、推动制造知识智能化复用具有工程实用价值。

Abstract： This project designs and implements a lightweight enterprise manufacturing process generation system based on Retrieval-Augmented Generation (RAG). It addresses the heavy reliance on expert experience, the low efficiency of manual process-manual lookup, and the hallucination and lack of traceability of general-purpose large language models (LLMs). The system adopts an offline-indexing plus online-questioning architecture. The offline pipeline parses process PDFs, extracts tables, splits documents into chunks, and builds a dense vector index with Chroma and a sparse BM25 index. The online pipeline rewrites multi-turn queries, performs hybrid retrieval (dense plus sparse), fuses results with Reciprocal Rank Fusion (RRF), and re-ranks candidates with a Cross-encoder. The LLM then generates structured machining instructions with citable sources. Built on open-source Chroma, BGE-M3, bge-reranker and an LLM API, the system provides document parsing, hybrid retrieval, reranking, multi-turn dialogue and citation traceability, and is evaluated by human assessment across multiple documents.

</td></tr>
<tr><td>主题词</td><td colspan="2">

主题词数量不多于三个，主题词之间空一格（英文用“/ ”分隔）

中文	**检索增强生成　混合检索　工艺生成**
英文	**Retrieval-Augmented Generation / Hybrid Retrieval / Process Generation**

</td></tr>
</table>

二、选题依据

1. （一）研究意义与工程价值

机械加工工艺是连接产品设计与制造的桥梁，零件的加工方法、刀具选择以及切削速度、进给量、背吃刀量等工艺参数直接决定了零件的加工质量、生产效率和制造成本。长期以来，工艺知识主要沉淀在厚重的工艺手册、企业技术标准以及经验丰富的工艺人员头脑中。面对一个新零件，工艺人员往往需要反复翻阅手册、比对参数，知识获取效率低、对人员经验依赖强，且存在知识传承困难、标准更新不及时等问题。

近年来，以大语言模型（LLM）为代表的人工智能技术在知识问答和文本生成方面表现突出，但直接将通用大模型用于工艺生成存在三个突出问题：一是其训练数据中缺乏企业或行业内部的专业工艺资料，知识覆盖不全；二是模型会“一本正经地编造”参数（即幻觉），而切削参数错误可能导致刀具崩损、零件报废甚至安全事故；三是生成结果缺乏来源依据，无法核对与追溯，难以满足工程领域对可验证、可担责的要求。

检索增强生成（RAG）通过“先检索、后生成”的方式，让模型基于权威资料作答，能够有效缓解上述问题。本项目面向机械加工场景，构建一个轻量级、可落地的企业级工艺生成系统，将工艺手册中的参数转化为可检索、可溯源的知识，自动生成结构化加工指令，对于降低工艺知识获取门槛、缩短工艺准备周期、推动制造知识智能化复用具有明确的工程价值和应用前景。

（二）国内外研究概况与发展趋势

在技术演进上，Lewis 等人于 2020 年正式提出检索增强生成（RAG）框架[1]，通过在生成前从外部知识库检索相关证据来增强模型能力，此后 RAG 成为大模型领域最活跃的方向之一。在嵌入模型方面，向量表示从早期的通用模型发展到面向中文的 BGE[2]、M3E 等系列，其中智源研究院的 BGE-M3 模型[3]在同一框架内支持稠密、稀疏和多向量检索，并具备多语言、长文本能力；在检索策略上，业界普遍采用“向量语义检索 + 关键词检索（BM25）[4]”的混合召回，以兼顾语义理解与精确匹配；在精排环节，基于 BERT 的 Cross-encoder[5]（如 bge-reranker）成为提升检索精度的标准做法。

在系统与工程层面，LangChain[6]、LlamaIndex 等框架提供了文档加载、分块、检索、生成的完整组件，Chroma[7]、FAISS、Milvus 等向量数据库日趋成熟，极大降低了 RAG 系统的构建门槛。在应用层面，RAG 在机械制造、工艺设计等垂直场景仍处于探索阶段，尤其在工艺文档中大量存在的表格、参数、标准号等结构化信息的精确检索与可靠生成方面，仍有较大研究空间。

总体来看，RAG 正从“能问答”走向“可验证、可追溯、可工程化部署”的企业级应用[8]，混合检索、重排序、引用溯源与多轮对话成为高质量 RAG 系统的标准配置，这与本项目的建设目标高度一致。

（三）选题的先进性与实用性

先进性：一是采用稠密 + 稀疏双路混合召回并以 RRF[9] 融合，兼顾语义匹配与型号、数字等精确匹配；二是引入 Cross-encoder 重排序，对召回结果二次精排，显著提升检索精度；三是生

成结果结构化输出并逐条标注来源，支持定位到原文页码，满足工程可追溯要求；四是支持多轮对话与查询改写，更贴近真实的工艺咨询交互。

实用性：系统基于开源组件与轻量级向量数据库构建，部署成本低、可在普通设备运行；知识来源采用公开的机械加工工艺手册[10]、国家标准等权威资料，可平滑替换为企业内部文档；输出的结构化加工指令可直接供工艺人员参考，并通过人工评估验证其准确性，具备较强的落地推广潜力。

（四）技术难度及工作量

技术难度主要体现在：①工艺文档包含大量表格、参数和版面结构，通用解析易丢失表格的行列对应关系，需要专门处理表格抽取与分块保护；②机械参数、材料牌号、刀具型号对精确匹配要求高，需要设计稠密与稀疏互补的混合召回策略并合理融合；③需要通过重排序在有限候选中精确排序，平衡检索效果与响应速度；④生成结果需严格基于资料、避免幻觉，并实现引用的准确标注与溯源；⑤多轮对话中的指代消解与上下文管理。

工作量方面，本项目覆盖文档解析、分块、向量化、混合检索、重排序、生成、多轮对话、溯源、界面与评估等完整链路，由 4 名成员分工协作，需要完成从数据准备、算法实现、系统集成到多文档测试评估的全过程，工作量饱满。

2. 参考文献

[1] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]. Advances in Neural Information Processing Systems (NeurIPS), 2020.

[2] Xiao S, Liu Z, Zhang P, et al. C-Pack: Packed Data-Augmented Compact General Text Embeddings[J]. arXiv preprint arXiv:2309.07597, 2023.

[3] Chen J, Xiao S, Zhang P, et al. BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation[J]. arXiv preprint arXiv:2402.03216, 2024.

[4] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond[J]. Foundations and Trends in Information Retrieval, 2009, 3(4): 333-389.

[5] Nogueira R, Cho A. Passage Re-ranking with BERT[J]. arXiv preprint arXiv:1901.04085, 2019.

[6] LangChain. LangChain Documentation[EB/OL]. https://python.langchain.com, 2024.

[7] Chroma. ChromaDB Documentation[EB/OL]. https://docs.trychroma.com, 2024.

[8] Gao Y, Xiong Y, Gao X, et al. Retrieval-Augmented Generation for Large Language Models: A Survey[J]. arXiv preprint arXiv:2312.10997, 2023.

[9] Cormack G V, Clarke C L A, Buettcher S. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods[C]. Proceedings of SIGIR, 2009: 758-759.

[10] 王先逵. 机械加工工艺手册[M]. 2 版. 北京：机械工业出版社，2007.

三、课题内容及具体方案

1. 课题内容

本项目实现一个基于 RAG 的轻量级企业工艺生成系统，核心功能包括：（1）工艺文档（PDF）格式的自动解析，包括文字、表格、页码与版面结构；（2）稠密向量检索与稀疏 BM25 关键词检索相结合的混合召回；（3）基于 Cross-encoder 的重排序模块，提升检索精度；（4）支持多轮对话与引用溯源；（5）在多份文档上通过人工评估检验准确率。

1. 系统需求分析

功能性需求：①数据导入与解析，支持上传工艺 PDF 并自动抽取正文、表格、页码等；②知识库构建，对文档进行分块、向量化并建立稠密与稀疏索引；③工艺问答，用户输入零件信息或加工要求，系统返回结构化加工指令；④混合检索与重排序，保证参数检索的完整性与准确性；⑤多轮对话，支持上下文追问与查询改写；⑥引用溯源，每条参数标注来源文档与页码，可点击核对；⑦结果结构化输出，按工序、刀具、切削参数等组织，并支持 JSON 输出。

非功能性需求：①准确性，检索与生成结果应忠实于资料，资料不足时明确提示，不编造参数；②可追溯，关键结论可定位到原文；③轻量性，基于 Chroma 等轻量组件，可在普通计算机运行；④易用性，提供图形化交互界面；⑤可扩展，支持持续追加文档，并可平滑替换为企业内部知识库。

2. 系统概要设计

系统采用“离线建库 + 在线问答”双链路架构，主要模块及数据流如下：

离线建库链路：①文档解析模块使用 PyMuPDF 提取文字、页码与版面，使用 pdfplumber 抽取表格结构；②分块模块采用递归字符分块，并对完整表格进行保护、相邻块保留重叠，每个块记录来源文档、页码、章节等元数据；③向量化模块使用 BGE-M3 嵌入模型生成稠密向量；④索引模块在 Chroma 中写入稠密向量，同时使用 rank_bm25 构建稀疏关键词索引。

在线问答链路：①对话管理模块记录历史并通过大模型对追问进行查询改写，将含代词、省略的问题补全为独立问题；②混合召回模块并行执行向量检索与 BM25 检索；③融合模

块采用 RRF（k=60）合并两路结果并去重；④重排序模块使用 bge-reranker-v2-m3 对候选块进行 Cross-encoder 精排，取 top 3~5；⑤生成模块将系统规则、检索资料、对话历史与问题拼装为 Prompt，调用大模型生成带引用的结构化加工指令；⑥溯源模块依据元数据渲染可点击的来源链接。

系统总体采用分层、模块化设计，便于分工开发与独立测试；通过 Gradio 提供 Web 对话界面，并将各检索、生成组件封装为可复用模块。

3. 拟采用的开发方法、环境，测试方案等

开发方法：采用模块化、迭代式开发，按“文档解析与建库 → 混合检索与重排序 → 生成与多轮对话 → 溯源与界面 → 测试评估”的顺序分阶段推进，每个模块先独立实现与单元测试，再进行系统集成。

开发环境：操作系统 macOS；编程语言 Python 3.10+；RAG 框架 LangChain；向量数据库 Chroma；稀疏检索 rank_bm25；嵌入模型 BGE-M3；重排序模型 bge-reranker-v2-m3；PDF 解析 PyMuPDF 与 pdfplumber；生成大模型采用 DeepSeek（通过学校统一 API 接口，兼容 OpenAI 协议）；界面使用 Gradio；代码使用 Git 进行版本管理并托管于 GitHub。嵌入与重排序模型可通过 API 或本地部署两种方式运行，并进行对比。

测试方案：①功能测试，验证 PDF 解析、表格抽取、混合检索、重排序、生成、溯源等各模块的正确性；②多文档测试，选取多份公开工艺手册及自建工艺文档，构建典型工艺问题测试集；③人工评估，由评估人员根据参考答案对检索结果的相关性、生成参数的正确性、引用的准确性进行打分；④对比实验，比较“仅向量检索 / 向量+BM25 / 混合检索+重排序”等不同配置下的召回与生成效果，分析各模块的贡献。

4. 技术难度及特色分析

特色与难点之一是面向工艺文档的表格与参数处理：通过解析阶段保留表格结构、分块阶段保护完整表格、检索阶段依靠 BM25 精确匹配型号数字，缓解纯向量检索对数字、牌号不敏感的问题。

特色之二是“混合召回 + 重排序”的两级检索：以双路召回保证不遗漏，以 Cross-encoder 精排保证准确，兼顾检索质量与响应速度。

特色之三是强约束的可信生成与引用溯源：通过 Prompt 约束模型“只依据资料作答、资料不足即声明”，并将每条参数与来源页码绑定，实现可核对、可追溯的加工指令。

特色之四是轻量与可扩展：全部基于开源、轻量组件，可在普通设备运行，知识库可增量更新，且可平滑迁移到企业内部资料，具有良好的工程推广价值。

四、工作进度的大致安排

项目周期为 2026 年 10 月至 2027 年春季学期，按以下阶段推进，各阶段明确成果形式。

阶段 / 时间	主要工作	成果形式
第 1 阶段 2026.10—2026.11 文献调研与需求分析	研读 RAG、混合检索、重排序相关文献与开源框架；完成开题报告；明确需求与系统架构；搭建开发环境与 GitHub 仓库。	开题报告、文献综述、系统需求与架构设计、项目仓库
第 2 阶段 2026.11—2026.12 文档解析与离线建库	实现 PDF 文字与表格解析、语义分块与表格保护；完成 BGE-M3 向量化与 Chroma、BM25 索引构建。	文档解析与建库模块、可检索知识库
第 3 阶段 2026.12—2027.01 混合检索与重排序	实现稠密向量检索、BM25 检索、RRF 融合与 Cross-encoder 重排序；进行召回参数调优。	混合检索与重排序模块、初步检索评测
第 4 阶段 2027.02—2027.03 RAG 生成与多轮对话	完成 Prompt 工程、大模型 API 接入与结构化输出；实现对话历史管理与查询改写。	生成与多轮对话模块、可运行问答原型
第 5 阶段 2027.03—2027.04 引用溯源与交互界面	实现基于元数据的页码定位与来源高亮；完成 Gradio Web 界面；系统集成联调。	完整可演示系统、Web 交互界面
第 6 阶段 2027.04—2027.05 多文档测试与优化	构建测试问题集，开展人工评估与对比实验；分析结果并优化解析、分块与检索策略。	测试评估报告、优化后的系统
第 7 阶段 2027.05—2027.06 结题与答辩	整理代码与文档，撰写结题报告和技术报告，准备答辩材料。	结题报告、技术文档、源码、系统演示

预期成果及特色

1. 一套可运行的基于 RAG 的轻量级企业工艺生成系统，覆盖文档解析、混合检索、重排序、多轮对话、引用溯源等完整功能，提供 Web 交互界面。

2. 结构化的零件加工指令生成能力，参数忠实于资料、可定位到原文页码，支持资料不足时的安全提示。

3. 完整的源码与工程文档，代码托管于 GitHub，具备清晰的模块结构与使用说明。

4. 多文档测试与人工评估报告，包含测试问题集、评估结果及不同检索策略的对比实验。

5. 结题报告与技术报告，总结系统设计、关键技术与改进方向。

导师意见（对选题和工作过程及成果进行说明，并给出成绩。）

导师签名：

年　　月　　日

答辩小组意见
答辩组长签名： 年　　月　　日